

YAPAY ZEKÂ DESTEĞİ İLE PANORAMİK DİŞ RÖNTGENLERİNDE DENTAL BULGULARIN TESPİTİ

İREM SELEN

ÜMMÜGÜLSÜM EROL

19 HAZİRAN, 2025

Genel Bakış

BİLGİSAYAR MÜHENDİSLİĞİ, 2025

01
Özet

05
Bulgular ve Tartışma

02
Literatür Taraması

06
Sonuç


03
Veri Setleri

07
Gelecek Çalışmalar

04
Kullanılan Yöntem



Özet



Bu çalışmada 3D panoramik dental röntgen görüntüleri CNN ve YOLO gibi yöntemlerle eğitilerek dental sınıflandırma yapmak amaçlanmıştır. Yapay zeka modelleri oluşturulmuş, test edilmiş, sonuçlar karşılaştırılmıştır. Çalışma genelinde Caries (çürük), Filling (dolgu), Root Canal Treatment (Kanal Tedavisi), Implant ve Impacted Tooth (Gömülü diş) olmak üzere 5 sınıfa odaklanılmıştır.



Literatür Taraması



Hua ve arkadaşları tarafından yapılan "YOLO-DentSeg: A Lightweight Real-Time Model for Accurate Detection and Segmentation of Oral Diseases in Panoramic Radiographs" başlıklı çalışmada YOLO-DentSeg isminde yeni bir model geliştirilmiştir. Çalışmada YOLOv8n-seg çerçevesinin geliştirilmiş bir versiyonuna dayanan, ağız ve diş hastalıklarının gerçek zamanlı tespiti ve segmentasyonu için tasarlanmış YOLO-DentSeg modeli sunulmaktadır. Yapılan deneyler DentSeg modelinin YOLOv8n-seg ile karşılaştırıldığında; model boyutu, hesaplama yükü ve parametre sayısını azalttığını ayrıca daha yüksek hassasiyet ve daha hızlı çıkarım süreleri elde ettiğini göstermektedir.

Literatür Taraması




Ünsal ve Adem, tarafından gerçekleştirilen panoramik diş röntgenlerindeki diş çürüklerinin tespit edilmesi için derin öğrenme yöntemlerini kullanan çalışmada veri seti olarak 553 hastanın panoramik diş röntgenleri kullanılmıştır. Faster-R-CNN ve Yolov5 karşılaştırılmış, en başarılı sonuçların Yolov5 modeliyle elde edildiği görülmüştür. Dolgu ve kanal görüntülerinde %98, köprü görüntülerinde ise %85 doğruluk oranına ulaşılmıştır .

Hasnain ve arkadaşları, diş radyografilerinin otomatik analizi için konvolüsyonel sinir ağları (CNN) kullanan bir çalışma gerçekleştirmişlerdir. Veri seti olarak İran'daki Noor Tıbbi Görüntüleme Merkezi'nden alınan yüzden fazla hastanın anonimleştirilmiş panoramik diş röntgenleri kullanılmıştır. Model, eğitim sürecinde %94.80, test aşamasında ise %97.87 doğruluk değeri elde etmiştir

Veri Setleri


BİLGİSAYAR MÜHENDİSLİĞİ, 2025



3.1. Dental Radiography Veri Seti

3.1. Dental Radiography Veri Seti

Toplamda 1269 adet röntgen görüntüsünden ve 4 sınıftan oluşan bu veri seti train, validation ve test olarak ayrılmıştır. İlerleyen aşamalarda YOLO ile eğitime devam edilmeye karar verildiği için bu veri seti ile devam edilmemiştir.



3.2. Dental X-Ray Panoramic Dataset Veri Seti

3.2. Dental X-Ray Panoramic Dataset Veri Seti

Toplamda 13376 görüntüden oluşan veri seti YOLO için test, train ve valid olmak üzere üç klasöre ayrılmıştır. Bu veri setinde çürük, kron, dolgu, implant gibi 31 farklı sınıf vardır. Bu veri setinde arttırım yapıldığı ve hatalı etiketler kullanıldığı için önce görüntüler filtrelenmiş, sonrasında bu filtreli görüntülerin bir kısmı ayrılarak optimize edilmiştir. 1128 görüntüden oluşan yeni veri seti %70 train, %20 validation ve %10 test olarak ayrılmıştır.

Kullanılan Yöntem

CNN

Çalışmanın ilk aşamalarında CNN ile eğitimler gerçekleştirilmiştir. CNN mimarileri medikal görüntüleme uygulamalarında yaygın olarak kullanılmalarına rağmen dental radyografilerde çoklu nesne tespiti ve lokalizasyon gereksinimleri söz konusu olduğunda yetersiz kalabilmektedir. Bu aşamada YOLO serisi modeller daha etkili çözümler sunmaktadır.

YOLO

Çalışmanın devamında YOLO ile eğitimler gerçekleştirilmiştir. YOLO, gerçek zamanlı nesne tespiti için kullanılan bir derin öğrenme modelidir. Diş görüntülerinin çok nesneli yapısı sebebiyle sınıflandırılmasında segmentasyon performansı etkileyen önemli bir özelliktir. YOLOv8 ve YOLOv11' gerçek zamanlı tespit ve yüksek hassasiyet sağlama özellikleriyle çalışmamızda tercih edilmiştir.


HAZIR MODELLER

Çalışmamız sırasında araştırdığımız bir diğer konu ise hazır modellerdi. Hem güncel ve aktif çalışan modellerden haberdar olup test etmek hem de çalışmamızda faydalanabilir ve kendi sonuçlarımızla karşılaştırabilir miyiz öğrenmek için eğitilmiş model araştırması yaptık. Paylaşılmış hazır modeller bulduk fakat bunlar segmentasyon için kullanılan modeller olduğu için kullanmadık.

Kullanılan Yöntem


Diş röntgen görüntülerinden hastalık tespiti için detaylar belirleyici rol oynamaktadır. Görüntü kalitesinin modelin başarısını doğrudan etkileyeceği öngörüsüyle, görüntü kalitesini artırmaya yönelik bir ön işleme adımı olarak CLAHE metodu tercih edilmiştir.

CLAHE metodu, medikal görüntü işleme alanında yaygın olarak kullanılan gelişmiş bir kontrast iyileştirme tekniğidir.



Ön işleme öncesi görüntü

CLAHE uygulanmış görüntü




Bulgular ve Tartışma

6.1. DENTAL RADIOGRAPHY VERİ SETİ DENEY VE SONUÇLARI

Kaggle platformundan elde edinilen Dental Radiography veri setiyle yapılan ilk eğitimde nesne tespiti eğitime dahil edilmemiş deneme amaçlı basit bir CNN modeli oluşturulmuştur. Model %46 accuracy değeri ile oldukça zayıf bir performans göstermiştir. Sınıf genelinde en düşük performansı ise f1-score ile Cavity sınıfı vermiştir

Class	precision	recall	f1-score	support
Cavity	22	17	19	12
Fillings	49	65	56	57
Impacted Tooth	62	29	40	17
Implant	40	32	36	31



Bulgular ve Tartışma

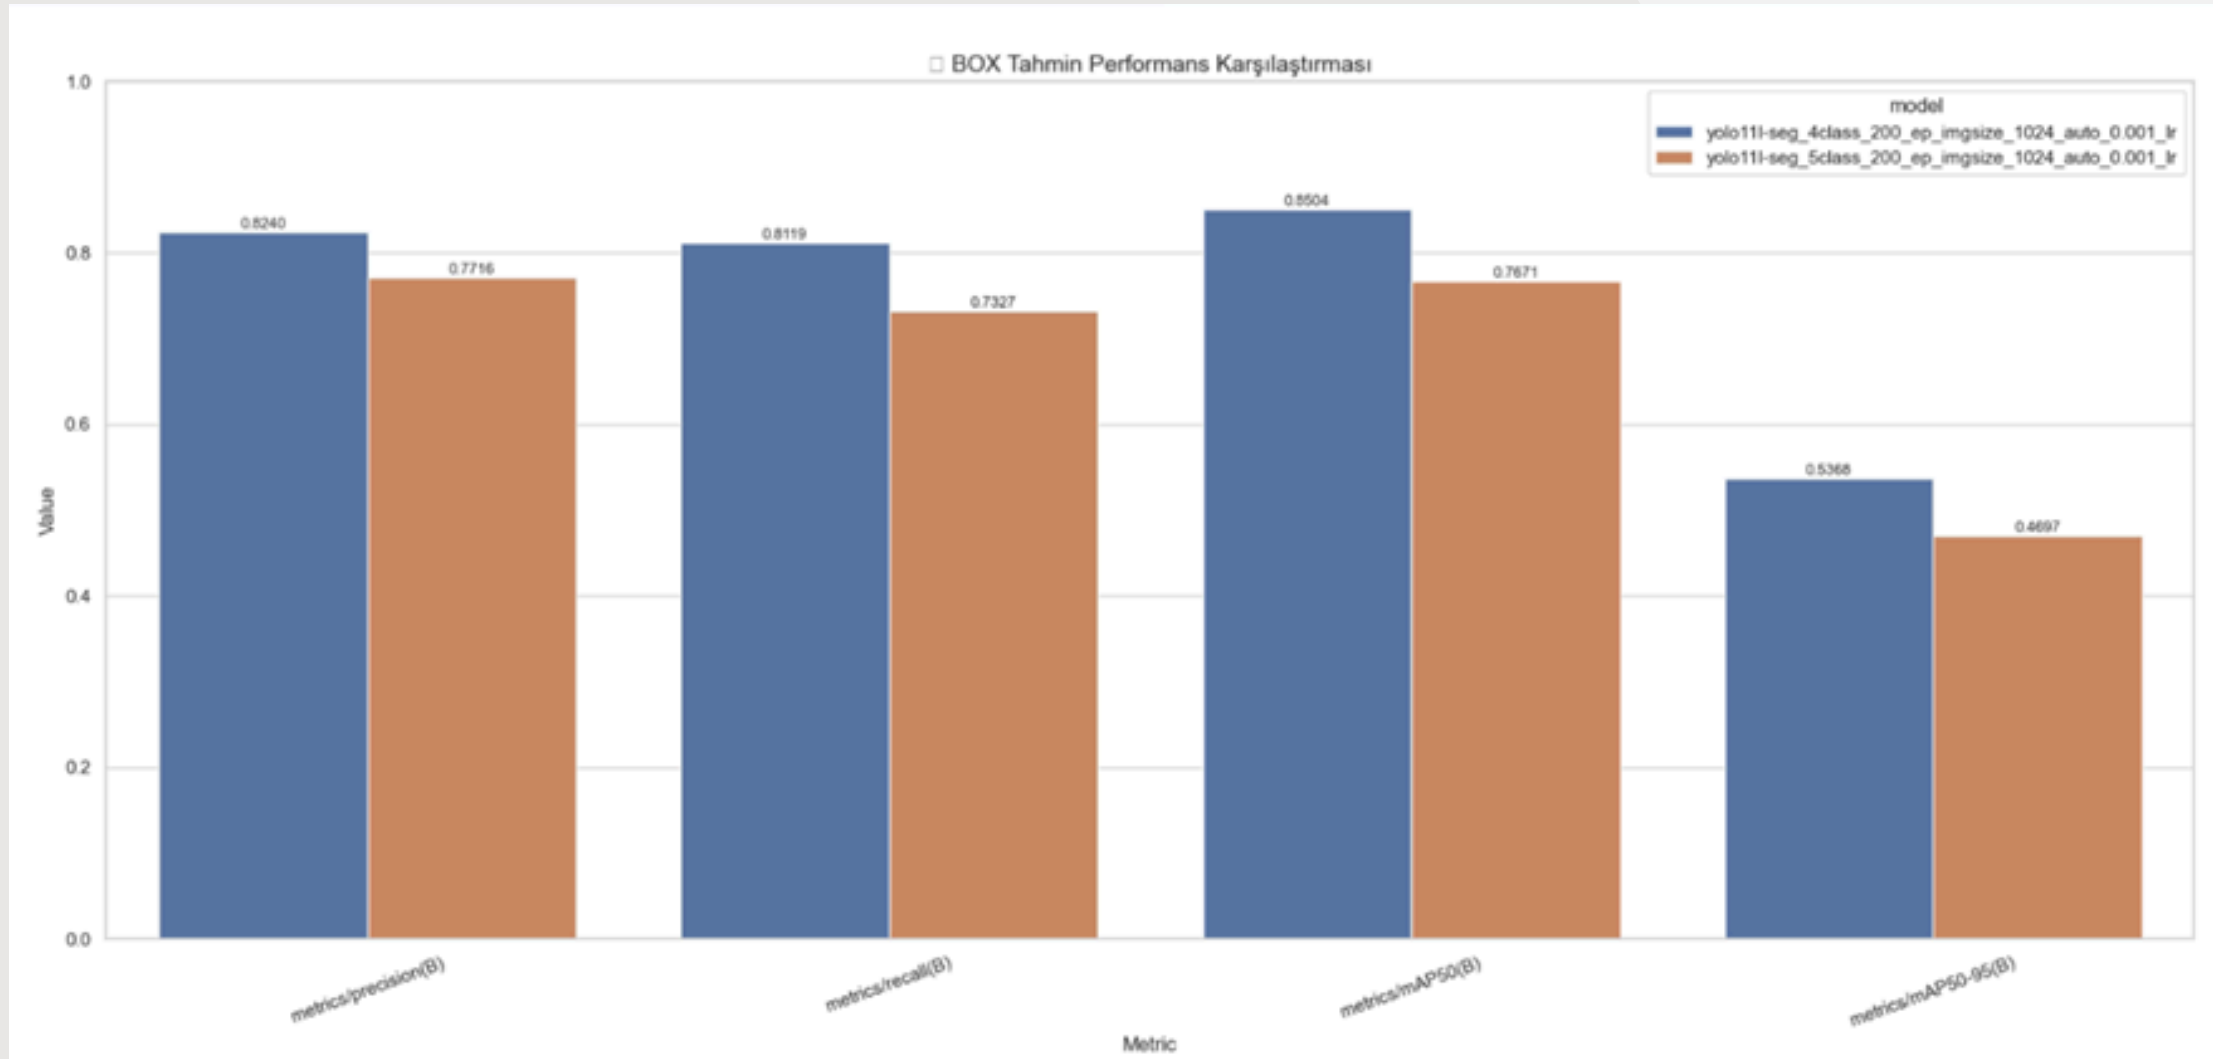
6.2. DENTAL X-RAY PANORAMIC DATASET VERİ SETİ DENEY VE SONUÇLARI

Model eğitilirken YOLOv8 modeli kullanılmıştır. Görüntü boyutu 640x640, batch size ise 16 olarak belirlenmiştir. Yani her iterasyonda 16 görüntü işlenmiştir. Model ilk önce 10 epoch ile eğitilmiştir, ama yeterli sonuç alınamadığı görüldüğünde 30 epoch ile eğitmeye karar verilmiştir

Class	Images	Instances	Box(P	R	mAP50	mAP50-95):
all	2871	27141	0.372	0.383	0.343	0.175
Caries	614	2180	0.359	0.18	0.162	0.0571
Crown	797	2087	0.625	0.93	0.79	0.506
Filling	2046	10058	0.477	0.719	0.626	0.296
Implant	109	240	0.769	0.912	0.891	0.533
Malaligned	4	5	0	0	0	0
Mandibular Canal	38	75	0.354	0.8	0.509	0.295
Missing teeth	257	541	0.409	0.573	0.471	0.192
Periapical lesion	471	1132	0.279	0.0981	0.0721	0.0191
Retained root	2	6	0	0	0.00175	0.00114
Root Canal Treatment	1061	3777	0.448	0.703	0.611	0.266
Root Piece	181	426	0.43	0.646	0.543	0.229
impacted tooth	2416	5859	0.796	0.965	0.906	0.558
maxillary sinus	27	54	0.309	0.741	0.39	0.262
Bone Loss	212	484	0.5	0.211	0.231	0.105
Fracture teeth	2	2	0	0	0	0
Supra Eruption	8	9	1	0	0.00928	0.00509
abutment	8	15	0	0	0	0
gingival former	2	2	0	0	0	0
metal band	1	1	1	0	0.995	0.399
orthodontic brackets	9	16	0.177	0.75	0.203	0.0914
post - core	25	38	0.165	0.12	0.0805	0.0252
wire	14	23	0.153	0.424	0.167	0.0661
Cyst	1	1	0	0	0	0
Primary teeth	9	110	0.686	0.427	0.561	0.287

Bulgular ve Tartışma

Model eğitimleri ilk aşamadan caries (çürük), filling (dolgu), implant, root canal treatment (kanal tedavisi), impacted tooth (gömülü diş) olmak üzere ilk başta 5 sınıf üzerinden gerçekleştirilmiştir.




Caries sınıfı tespit edilmesi oldukça zor bir sınıf olduğundan ve modelin performansı üzerindeki olumsuz etkisi tespit edildiğinden çalışmanın ilerleyen aşamalarında 4 sınıf üzerinde model eğitimleri uygulanmıştır. Şekilde görüldüğü üzere sınıflar arasından caries'in çıkarılması tüm metriklerde önemli bir artışa neden olmuştur.

Bulgular ve Tartışma

Eğitim metriklerinin Performansa Etkisini araştırmak amacıyla optimizer, learning rate, kullanılan modeller gibi metrikler değiştirilerek deneyler gerçekleştirilmiştir. Bunlardan öne çıkanlar aşağıdadır:

6.2.1. Optimizer Etkisi

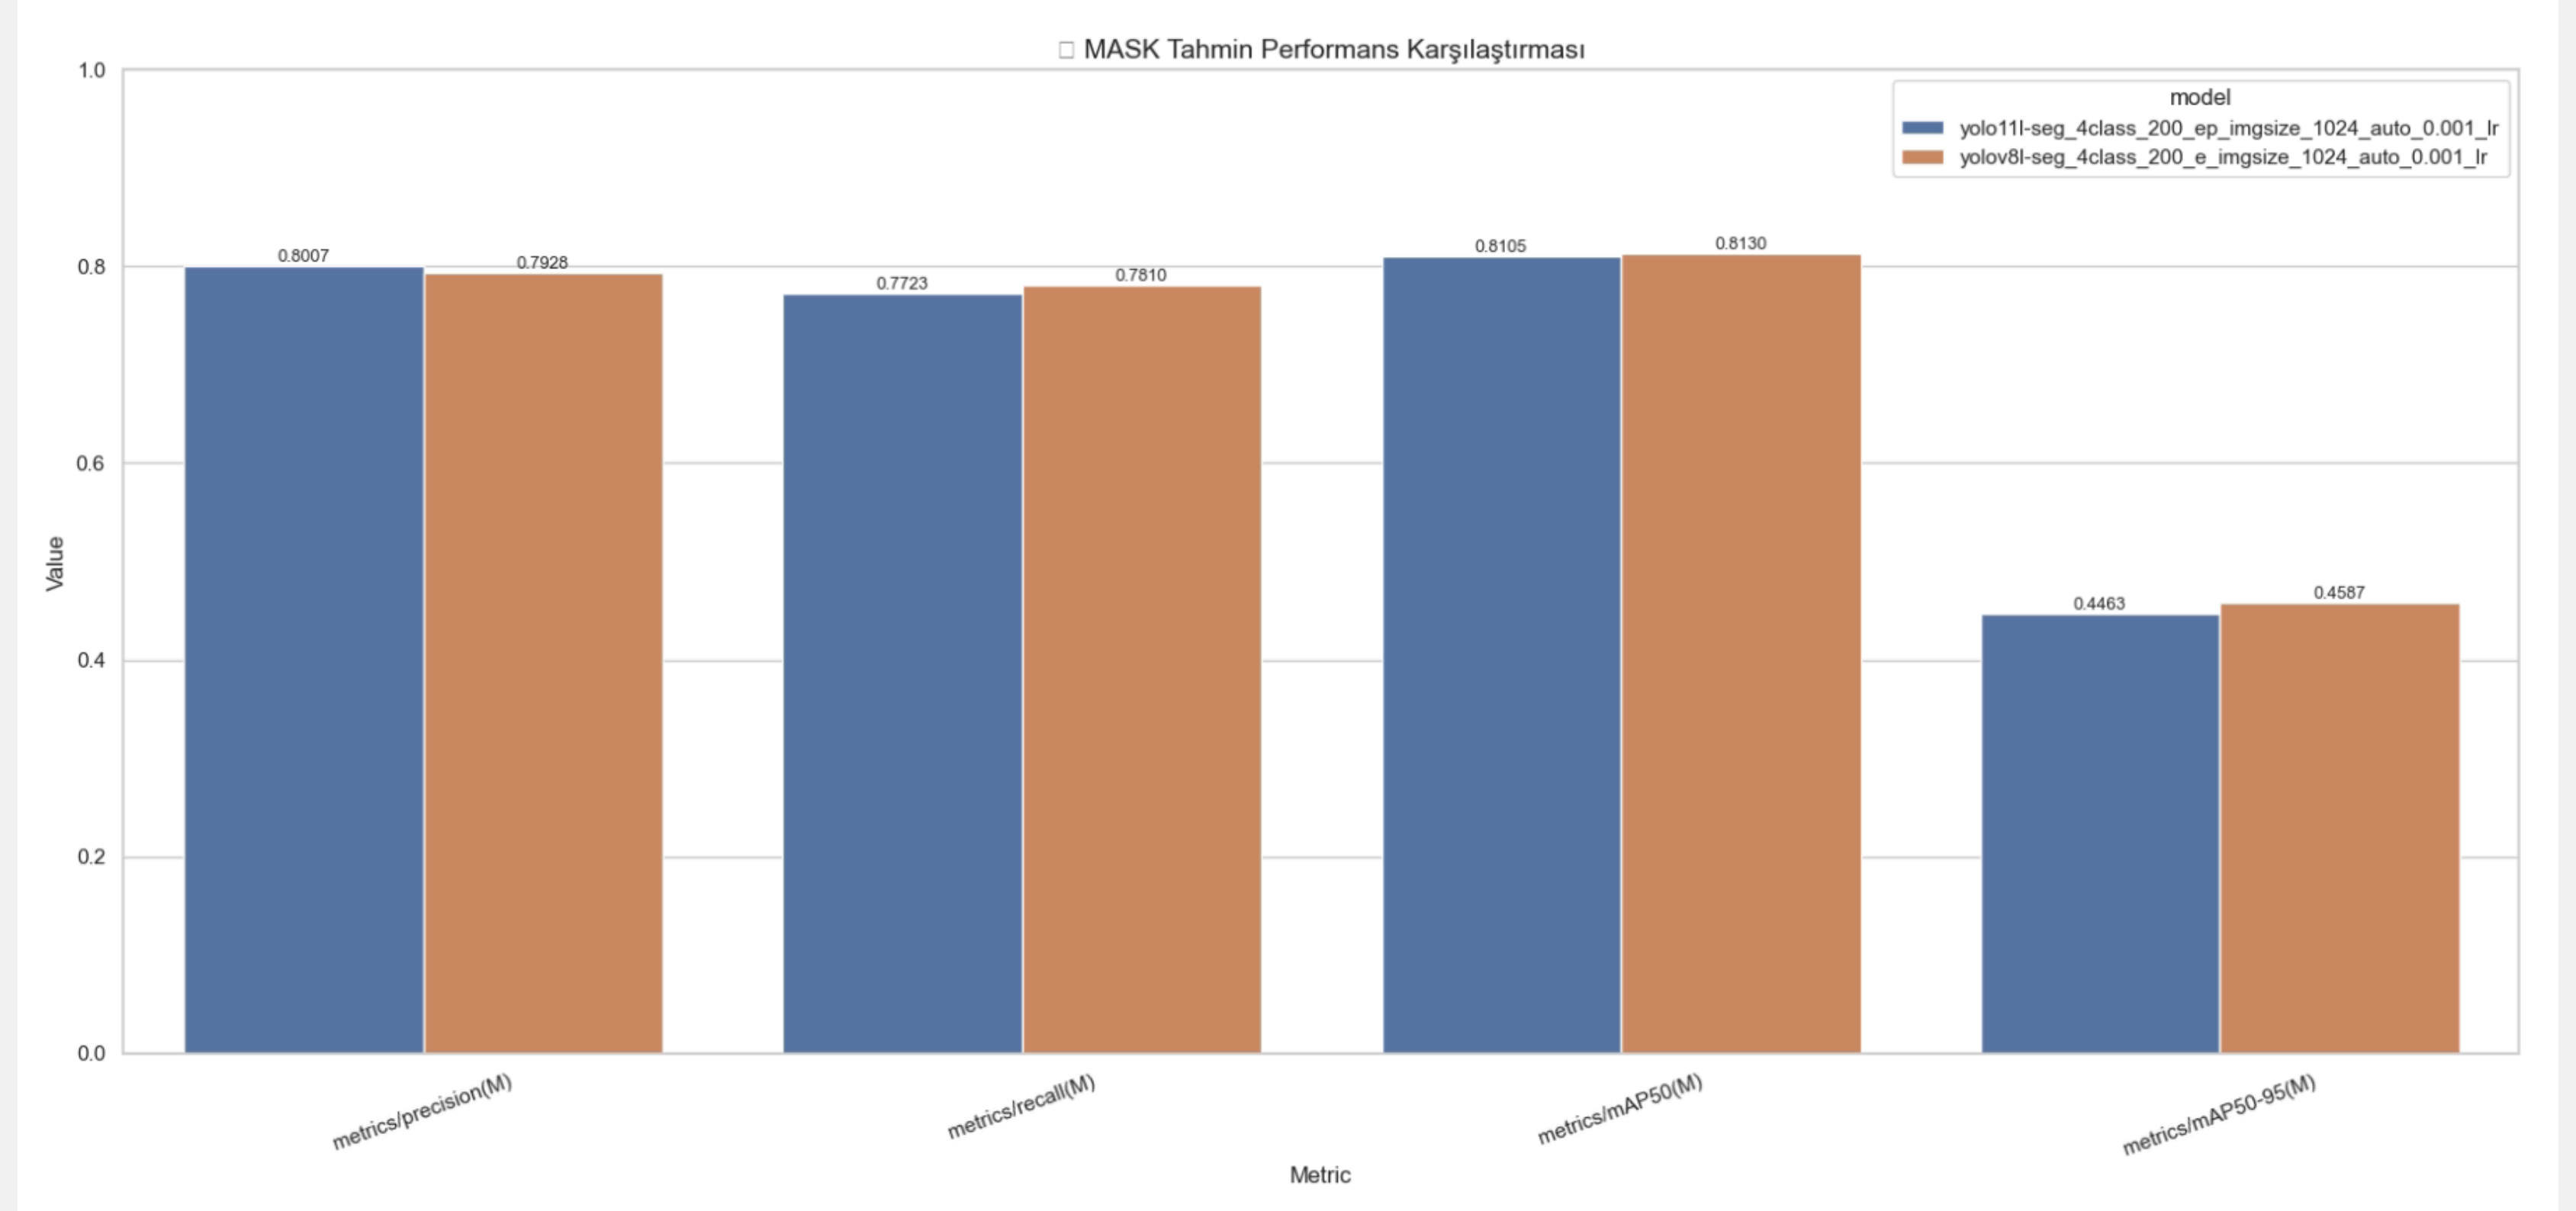
YOLOv11-l modeli kullanılarak, 1024 imgsize ve 0.001 learning rate ile 4 sınıf için eğitilmiş iki modelin karşılaştırılmasında Recall, Adam ile daha yüksek sonuç vermiştir. Ama precision ve mAP@50 değerlerinde küçük bir farkla auto daha iyi sonuç vermiştir.



Bulgular ve Tartışma

6.2.2. Model etkisi

YOLOv11-seg modelini kullandık ve YOLOv8-seg'den daha iyi bir performans aldık.




Sonuç

Çalışmamızda, Dental X-ray görüntülerinde çoklu diş problemlerini tespit etmek amacıyla 2 farklı veri kümesi ile 2 farklı derin öğrenme algoritması (CNN ve YOLO) kullanılarak modeller geliştirilmiş, sonuçları test edilmiştir. YOLO'nun çoklu nesne tespitinde daha başarılı olduğu görülerek YOLOv8 ve ardından YOLOv11-seg modelleri ve buna uygun veri kümesi tercih edilmiştir.

Başlangıçta 31 sınıfla eğitilen model, düşük başarı nedeniyle 5 ve sonrasında 4 sınıfa indirgenmiştir. Görüntü kalitesi CLAHE ile artırılmış, segmentasyon başarıları değerlendirilmiş, en iyi sonuç %85.57 mAP@50 ile YOLOv11-medium-seg modelinden elde edilmiştir. Sınıf sayısının azaltılması, veri temizliği ve gelişmiş konfigürasyonlar model performansını anlamlı şekilde artırmıştır.



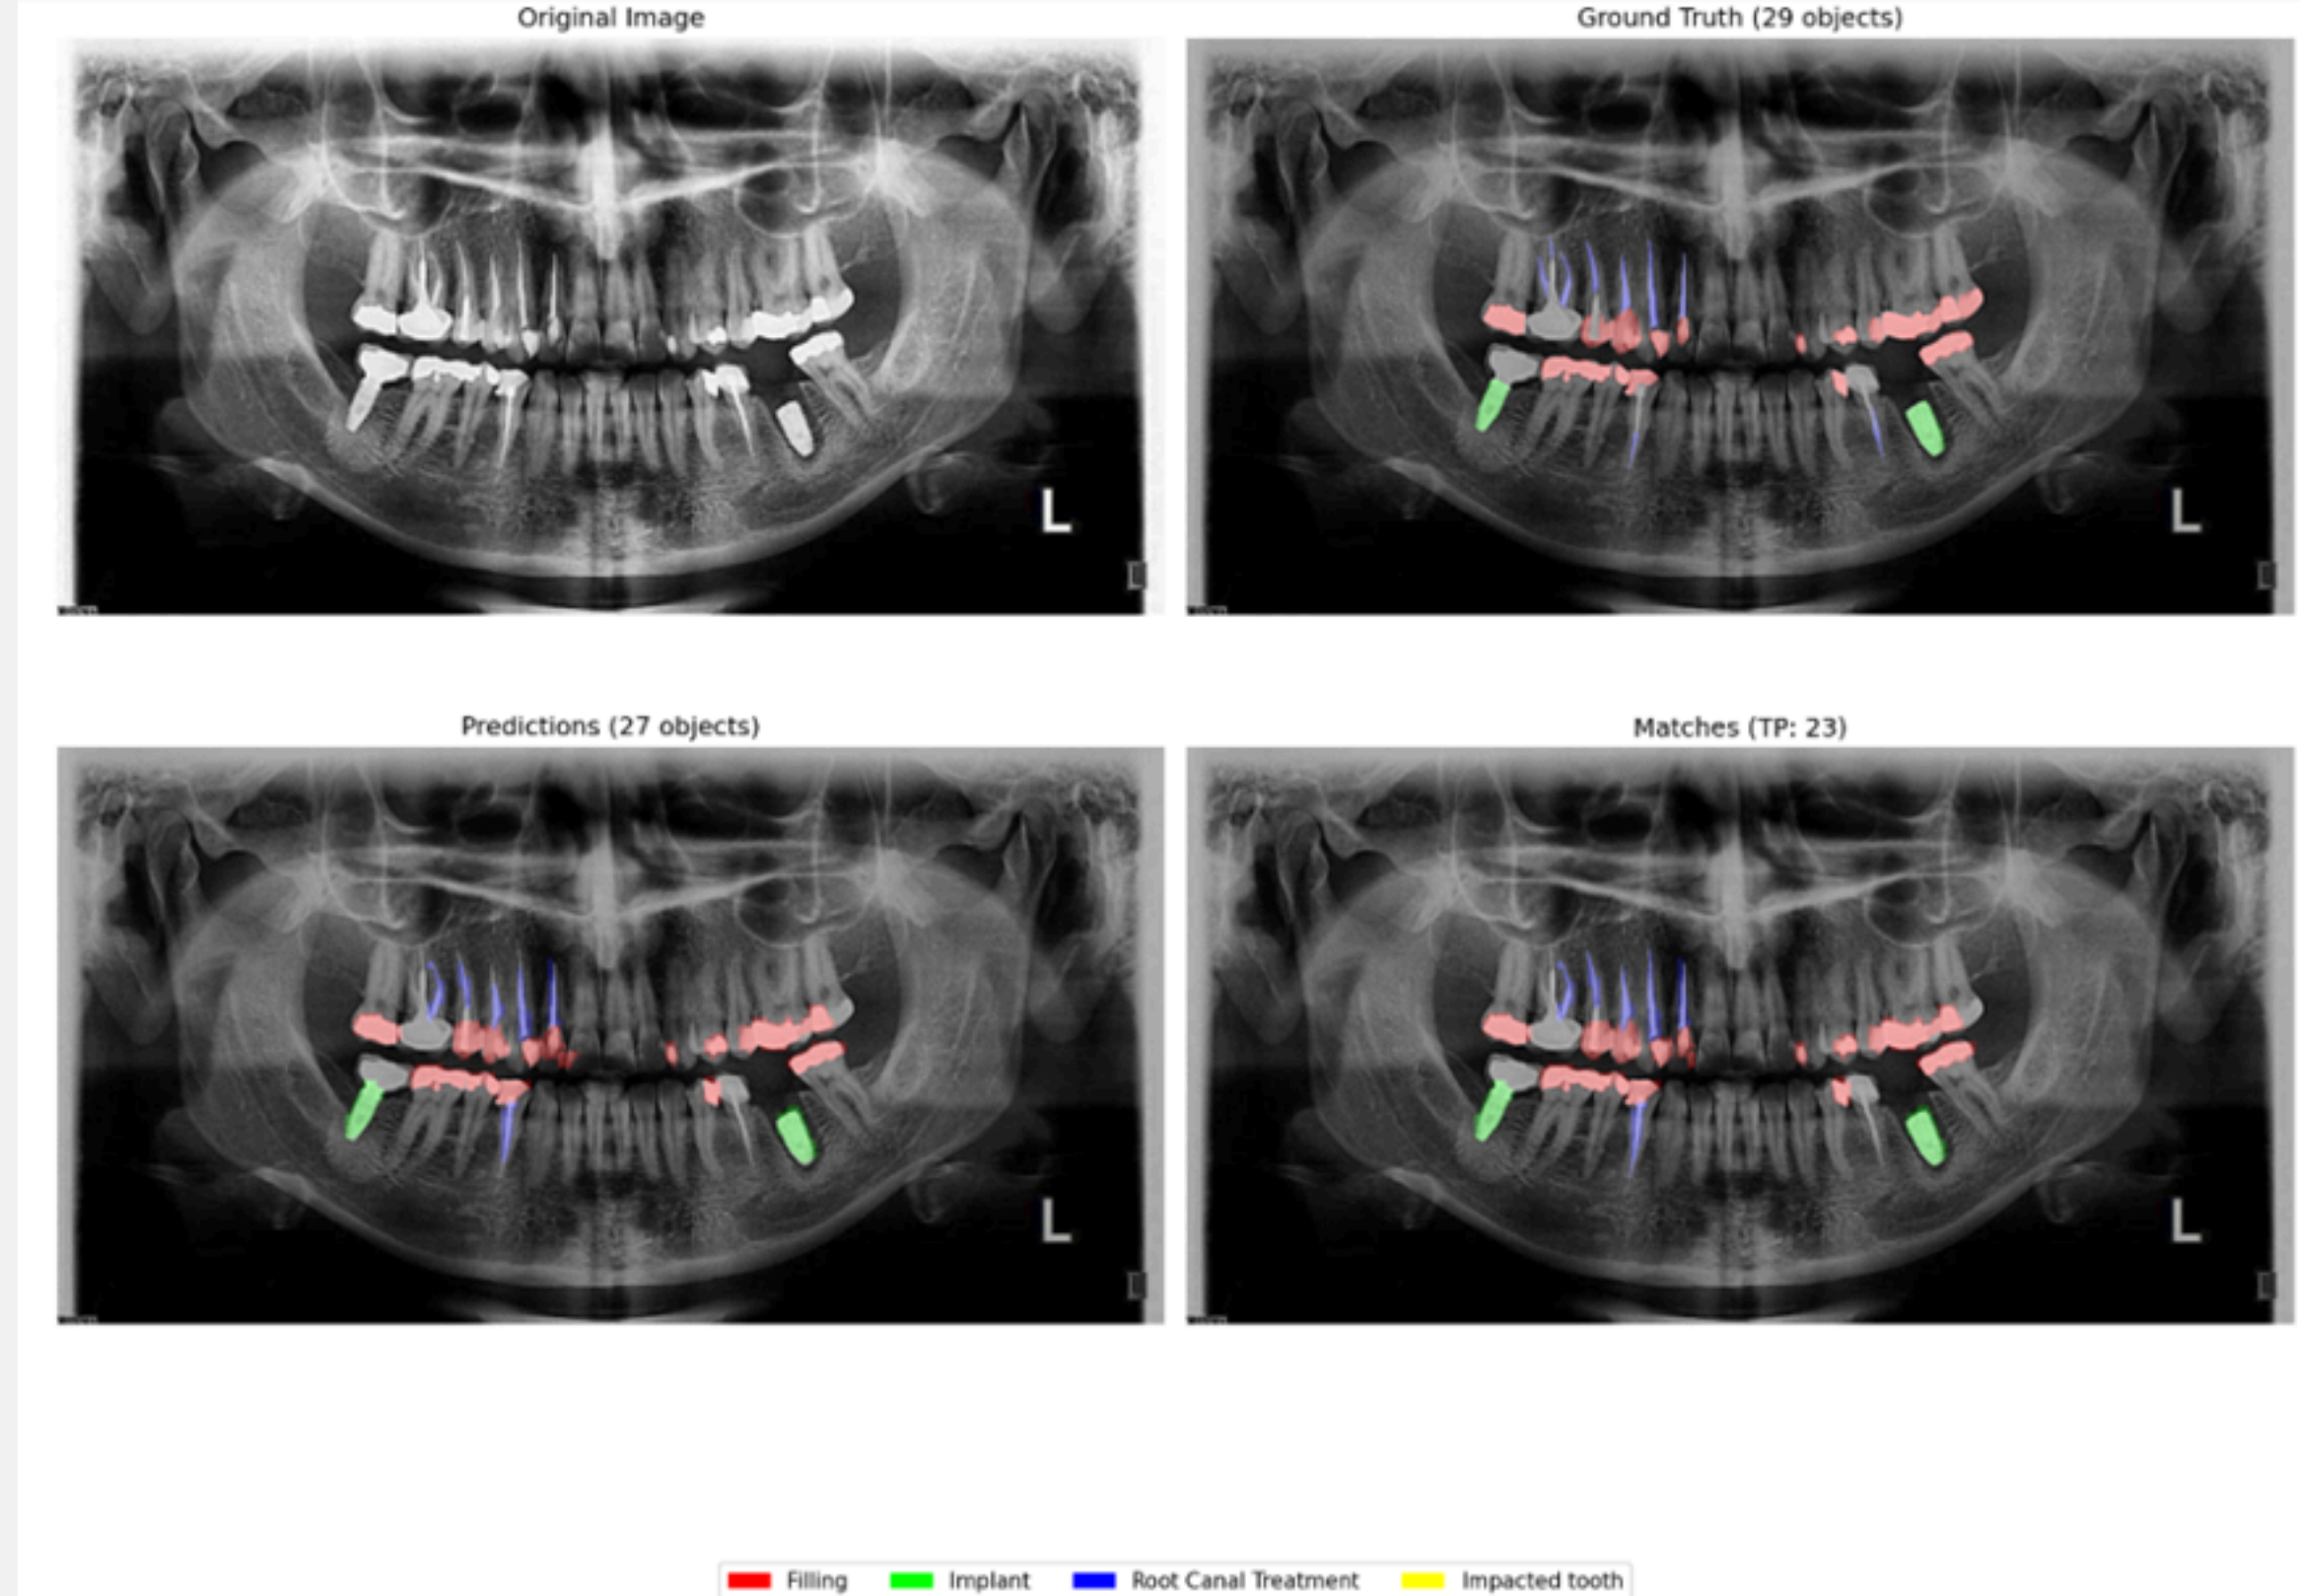
Model Karşılaştırması metrics/mAP50(B)



Sonuç

En iyi modelin performansını görsel olarak desteklemek ve tahmin yeteneğini somutlaştırmak amacıyla, dört farklı görselleştirme sunulmuştur. Bu görselleştirmeler sırasıyla orijinal görüntüyü ground truth etiketlerinin görüntü üzerindeki halini, modelin yaptığı tahminleri ve ground truth ile model tahminlerinin örtüştüğü durumları içermektedir.

Model 27 nesne tahmini yapmış ve bu tahminlerin 23'ü ground truth'lar ile başarılı bir şekilde eşleşmiştir. Bu durum, modelin yüksek doğruluk ve kapsama oranına sahip olduğunu görsel olarak teyit etmektedir



Gelecek Çalışmalar

NELER YAPILABİLİR?

Çalışma süresince hem diş hekimliği literatüründe hem de dental görüntü analizinde bilgi birikimi edinilmiş, birçok model çalıştırılmış ve sonuçlar karşılaştırılmıştır.

Veri setinin oldukça yetersiz olduğu saptanmıştır. Gelecekte daha düzenli ve profesyonel veri setleriyle çalışma imkanı bulunduğu taktirde daha tatmin edici sonuçlar alınacağı öngörülmektedir.

BİLGİSAYAR MÜHENDİSLİĞİ 2025

Teşekkürler

19 HAZİRAN, 2025