



Teknoloji Fakültesi

BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ

YAPAY ZEKÂ ALGORİTMALARI İLE PANORAMİK DİŞ RÖNTGEN GÖRÜNTÜLERİNDEN HASTALIK TESPİTİ

"

BİTİRME PROJESİ

Bilgisayar Mühendisliği Bölümü

DANIŞMAN

Doç. Dr. Ayşe Berna Altınel

İSTANBUL, 2025

"



Teknoloji Fakültesi

BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ

**YAPAY ZEKÂ ALGORİTMALARI İLE
PANORAMİK DİŞ RÖNTGEN
GÖRÜNTÜLERİNDEN HASTALIK TESPİTİ**

"

BİTİRME PROJESİ

Bilgisayar Mühendisliği Bölümü

DANIŞMAN

Doç. Dr. Ayşe Berna Altınel

İSTANBUL, 2025

"

MARMARA ÜNİVERSİTESİ
TEKNOLOJİ FAKÜLTESİ
BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ

Marmara Üniversitesi Teknoloji Fakültesi Bilgisayar Mühendisliği Öğrencileri İrem Selen ve Ümmügülsüm Erol tarafından “YAPAY ZEKÂ ALGORİTMALARI İLE PANORAMİK DİŞ RÖNTGEN GÖRÜNTÜLERİNDEN HASTALIK TESPİTİ” başlıklı proje çalışması, xxx tarihinde savunulmuş ve jüri üyeleri tarafından başarılı bulunmuştur.

Jüri Üyeleri

Dr. Öğr. Üyesi xxx xxx
Marmara Üniversitesi
Prof. Dr. Xxx xxx
Marmara Üniversitesi
Prof. Dr. Xxx xxx
Marmara Üniversitesi

(Danışman)

(Üye)

(Üye)

(İMZA).....

(İMZA).....

(İMZA).....

ÖNSÖZ

Proje çalışmamız süresince karşılaştığım bütün problemlerde, sabırla yardım ve bilgilerini esirgemeyen, tüm desteğini sonuna kadar yanımda hissettiğim değerli hocamız, sayın Doç. Dr. Ayşe Berna Altınel Girgin'e en içten teşekkürlerimizi sunarız.

İÇİNDEKİLER

1. GİRİŞ.....	1
1.1. Proje Çalışmasının Amacı ve Önemi.....	1
2. DİŞ RÖNTGEN GÖRÜNTÜLERİNİN SINIFLANDIRILMASINDA MAKİNE ÖĞRENMESİ UYGULAMALARI.....	2
3. VERİ SETLERİ.....	4
3.1. Dental Radiography Veri Seti	4
3.2. Dental X-Ray Panoramic Dataset Veri Seti	5
4. BULGULAR VE TARTIŞMA.....	7
4.1. Dental Radiography Veri Seti Deney ve Sonuçları.....	7
4.2. Dental X-Ray Panoramic Dataset Veri Seti Deney ve Sonuçları.....	9
4.3. Hazır Model Kullanımı.....	13
5. SONUÇLAR.....	14

ÖZET

YAPAY ZEKÂ ALGORİTMALARI İLE PANORAMİK DİŞ RÖNTGEN GÖRÜNTÜLERİNDEN HASTALIK TESPİTİ

Bu proje çalışmasında, etiketlenmiş ve sınıflandırılmış 3D panoramik dental röntgen görüntülerini CNN ve YOLO gibi yöntemlerle eğiterek hastalık tespiti yapmak amaçlanmıştır. Yapay zekâ modelleri oluşturulup sonuçları test edilerek performansları incelenmiş ve sonuçlar karşılaştırılmıştır. Bu sonuçlar incelenip çalışma için en performanslı model tercih edilerek yüksek doğruluklu sonuçlara ulaşmak hedeflenmiştir. Kullanıcı tarafından girilen panoramik diş röntgenlerinin çıktı olarak hastalıklı diş tespiti yapması amaçlanmış, ilk aşamada nesne tespiti ve sınıflandırma çalışmaları yapılarak sonraki adımlarda çalışmanın hastalık sınıfları odağında daraltılması hedeflenmiştir.

Haziran, 2025

Öğrenciler

ABSTRACT

DISEASE DETECTION FROM PANORAMIC DENTAL X-RAY IMAGES WITH ARTIFICIAL INTELLIGENCE ALGORITHMS

The aim of this project is to train labeled and classified 3D panoramic dental x-ray images with CNN and YOLO methods for disease detection. Artificial intelligence models were created and their results were tested and their performances were analyzed and the results were compared. These results were analyzed and the most efficient model was chosen for the study to achieve high accuracy results. It is aimed to detect diseased teeth as an output of panoramic dental x-rays entered by the user, and it is aimed to narrow the study in the focus of disease classes in the next steps by performing object detection and classification studies in the first stage.

June, 2024

Students

KISALTMALAR

CNN	: Convolutional Neural Networks
YOLO	: You Only Look Once
GPU	: Graphical processing unit
CPU	: Central processing unit
AI	: Artificial Intelligence
R-CNN	: Region-based Convolutional Neural Networks
FDA	: Food and Drug Administration
BBOX	: Bounding Box
ING	: İngilizce
SFNet	: Semantic Fusion Network
ResNet	: Residual Network
VGG	: Visual Geometry Group
mAP@0.5	: Mean Average Precision at IoU 0.5
IoU	: Intersection over Union

ŞEKİL LİSTESİ

Şekil 4.1 İlk denenen basit CNN modelinin mimarisi	7
Şekil 4.2 Bounding box kullanılarak eğitilen nesne tespitli model mimarisi.....	8
Şekil 4.3 Model v.2'nin dışarıdan bir veriyle yapılmış test sonuçları.....	9
Şekil 4.4 Modelin rastgele iki test verisi üzerindeki çıktıları.....	10
Şekil 4.5 Modelin sınıf bazlı performans metrikleri	11
Şekil 4.6 Confusion Matrix.....	12
Şekil 4.7 Precision, Recall, Confidence, F1 Grafikleri	13

TABLO LİSTESİ

Tablo 4.1 İlk modelin performans metrikleri

7

1. GİRİŞ

Herkesin hayatında en az bir kere deneyimlediği diş rahatsızlıkları birçok insanın günlük yaşantısını olumsuz etkilemektedir. Hastaların randevu bulamama, yanlış/eksik teşhislerle maruz kalma, fiziki ve coğrafi yetersizlikler gibi sebeplerle mağdur olduğu birçok durum karşımıza çıkmaktadır. Yapay zekâ çağı olarak nitelendirdiğimiz günümüz koşullarında her yanımız yapay zekâ araçlarıyla çevrili; yapay zekâ destekli uygulamalar, yapay zekâ destekli projeler, günlük hayatımızdan profesyonel iş hayatımıza kadar yaşantımızın bir parçası haline gelmiş durumdadır. Kimi zaman basit gündelik ihtiyaçlarımızı kolaylaştıran yapay zekâ, kimi zaman da teknolojik gelişmeler için bize kapıyı açan bir yol gösterici olmaktadır.

Teknolojik ilerlemenin öneminin en kritik olduğu alanlardan biri olan sağlık alanına da her geçen gün önemli yenilikler gelmektedir, buna rağmen ihtiyaç duyulan çalışmaların sayısı hala oldukça fazladır. Röntgen görüntülerinden hastalık tespiti birçok sağlık dalında hakkında çalışmalar yürütülen bir alandır. Beyin, iç organlar vb. röntgen çalışmalarıyla yapılan tümör, hastalık gibi durumların teşhisi konusundaki çalışmalar oldukça popülerdir. Diş röntgenleriyle yapılan benzer çalışmalar da vardır fakat bu alanlara kıyasla daha az sayıdadır. Bu çalışmalarda, diş röntgenlerini sınıflandırırken sınıflama işlemlerinin yanı sıra diş segmentasyonu yapmak, dişlerin radyografik görüntülerde tanımlanması ve klinik teşhisler için konum bilgisi sağladığından ağız sağlığı alanında kritik bir öneme sahiptir [1].

Ayrıca bu çalışmalar işinde yetkin diş hekimlerinin iş yükünü azaltarak gerek hastaların muayene kalitesini arttırmak gerek gelecek çalışmalar ve bunların sağlayacağı teknolojik gelişmeleri hızlandırmak için oldukça önemli bir potansiyele sahiptir.

1.1. Proje Çalışmasının Amacı ve Önemi

Yapay zekâ algoritmaları ile panoramik diş röntgen görüntülerinden hastalık tespiti projesi, diş hekimliği alanında teşhis ve tedavi süreçlerinde önemli bir teknolojik gelişim sunmayı hedeflemektedir. Bu çalışma, panoramik diş röntgenlerinde çürük, dolgu, kanal tedavisi ve implant gibi dental durumların otomatik tespiti ve sınıflandırılması için yapay zekâ algoritmaları kullanmaktadır.

Günümüzde diş hekimleri yoğun klinik ortamlarda sınırlı süreler içerisinde hizmet vermek

durumundadır. Bu proje, hekimlerin iş yükünü iyileştirerek tanı koyma sürecini hem hızlandırmayı hem de doğruluk oranını artırmayı öncelikli hedef olarak belirlemiştir. Yapay zekâ destekli otomatik analiz sistemi, klinik verimliliği artırırken diş hekimlerinin iş yükünü de azaltacaktır.

Projenin diğer bir önemli bileşeni ise bir diş röntgeni veri tabanının oluşturulmasıdır. Bu doğrultuda şimdiye kadar 100'den fazla diş röntgeni toplanmış olup, uzman görüşleri doğrultusunda etiketleme çalışmaları sürdürülmektedir.

2. DİŞ RÖNTGEN GÖRÜNTÜLERİNİN SINIFLANDIRILMASINDA MAKİNE ÖĞRENMESİ UYGULAMALARI

Tıbbi görüntülerin analizi ve sınıflandırılması, makine öğrenmesi ve derin öğrenme tekniklerinin sağlık alanında başarıyla uygulandığı önemli bir alan haline gelmiştir. Diş röntgenleri üzerinde yapılan çalışmalar, diş hekimlerine tanı koymada yardımcı olmak, iş yükünü azaltmak ve teşhis doğruluğunu artırmak amacıyla giderek yaygınlaşmaktadır.

Zeng ve arkadaşları, tıbbi görüntülerden otomatik teşhis raporu oluşturma amacıyla bir çalışma gerçekleştirmişlerdir. Anlamsal Füzyon Ağı (SFNet) olarak adlandırdıkları modelleri, lezyon alanı tespiti ve tıbbi görüntü teşhisi için ayrı modellerden oluşmaktadır. Bu yaklaşım, lezyon tespiti, patolojik bilgi çıkarımı ve rapor oluşturma görevlerini eş zamanlı olarak gerçekleştirmeyi sağlamaktadır. Çalışma kapsamında, Çin'deki Chongqing hastanesinden 25.659 hastanın ultrason görüntüleri ve raporları kullanılmış, ayrıca 7.470 X-ışını görüntüsü içeren Open-i veri kümesinden de yararlanılmıştır [2].

Ünsal ve Adem, panoramik diş röntgenlerinde diş çürüklerinin tespit edilmesi için derin öğrenme yöntemlerini kullanan bir çalışma gerçekleştirmişlerdir. Çalışmada, çürük dişler tedavi yöntemlerine göre dolgu, kanal ve köprü sınıflarına ayrılmıştır. Model performansını artırmak için görüntülere luv-v kanalı ve adaptif histogram eşitleme ön işlemleri uygulanmıştır. Veri seti olarak 553 hastanın panoramik diş röntgenleri kullanılmıştır. Derin öğrenme modellerinden Faster-R-CNN ve Yolov5 karşılaştırılmış, en başarılı sonuçların Yolov5 modeliyle elde edildiği görülmüştür. Dolgu ve kanal görüntülerinde %98, köprü görüntülerinde ise %85 doğruluk oranına ulaşılmıştır [3].

Suryani ve arkadaşları, diş panoramik röntgen görüntülerindeki nesneleri tespit etmek amacıyla Mask R-CNN modelini kullanmışlardır. Çalışma, diş radyografik yorumlamanın

zaman alıcı ve hataya açık sürecini kolaylaştırmayı hedeflemiştir. Veri seti olarak İran'daki Noor Tıbbi Görüntüleme Merkezi'nden alınan 116 hastanın anonimleştirilmiş panoramik diş röntgenleri kullanılmıştır. Eğitim için 110, test için 6 görüntü kullanılan çalışmada model panoramik diş görüntüsündeki nesneleri %91-%96 güven seviyesinde tespit edebilmiştir [4].

Hasnain ve arkadaşları, diş radyografilerinin otomatik analizi için konvolüsyonel sinir ağları (CNN) kullanan bir çalışma gerçekleştirmişlerdir. X-ışını görüntüleri "Normal" ve "Etkilenmiş" olarak iki sınıfa ayrılarak model geliştirilmiştir. Veri seti olarak İran'daki Noor Tıbbi Görüntüleme Merkezi'nden alınan yüzden fazla hastanın anonimleştirilmiş panoramik diş röntgenleri kullanılmıştır. Model eğitim sürecinde %94,80, test aşamasında ise %97,87 doğruluk değeri elde etmiştir. Bu sonuçlar aynı veri üzerinde test edilen VGG-16 ve ResNet modellerinden daha iyi performans göstermiştir [5].

Schwendicke ve arkadaşları, diş görüntü teşhisi için CNN kullanımını kapsayan sistematik bir inceleme sunmuşlardır. 2000 yılından 2019 yılına kadar yayınlanan çalışmaları kapsayan bu incelemede CNN'lerin diş hekimliğindeki uygulamaları, kullanılan yöntemler ve CNN performansının insan uzmanlarla karşılaştırılması ele alınmıştır. İncelemede, veri kümesi boyutlarının 10 ile 5.166 görüntü arasında değiştiği (ortalama 1.053 görüntü) belirtilmiştir. En yaygın kullanılan görüntü türü panoramik radyografiler olmuştur. En sık karşılaşılan uygulamalar %77-%98 doğruluk oranıyla diş sınıflandırması ve %82-%89 doğruluk oranıyla çürük lezyonların tespittir. CNN'leri insan uzmanlarla karşılaştıran on iki çalışmadan üçü CNN'lerin daha iyi, yedisi benzer, biri ise daha kötü performans gösterdiğini bulmuştur [6].

Günümüzde, diş hekimliğinde kullanılan FDA onaylı Overjet ve Pearl gibi yapay zekâ platformları dikkat çekmektedir. Overjet, Time dergisinin "2024 yılının en iyi icatları" yazısında kendine yer bulmuş olup çürükleri kırmızıyla, açıkta kalan sinirleri morla işaretleyerek diş röntgenlerini hastalar için anlaşılır kılmaya yardımcı olmaktadır. Pearl ise makine öğrenmesi ve bilgisayar görüşünü temel alan dental yapay zekâ çözümleri sunmaktadır [7, 8].

3. VERİ SETLERİ

3.1. Dental Radiography Veri Seti


Toplamda 1269 adet görsel veri ve 3 adet annotations dosyasından oluşan bu veri seti train, validation ve test olarak klasörlere ayrılmıştır. Eğitim için kullandığımız bu veri setinde 4 adet sınıf bulunmaktadır. Bunlar: Implant, Fillings (Dolgular), Impacted tooth (Gömülü diş) ve Cavity (Çürük) sınıflarıdır.


Veri setinde Bounding Box isimli bir yöntem kullanılmıştır. Bu yöntem ağız röntgenini belli bölgelere bölerek sınıflandırma yapmayı yani ağızdaki farklı dişleri tespit edip birden fazla diş tespit ederek sınıflandırılmasını sağlamayı amaçlamaktadır.

Her bir klasörün altında o klasöre ait _annotations.csv dosyası bulunmaktadır. Bu dosya görsellere ait bilgiler içeren 8 adet kolona sahiptir. Filename şeklinde temsil edilen ilk kolon dosya isimlerini gösterirken, width ve height değerleri kullanılan görsellerin genişlik ve yüksekliğinin kaç piksel olduğunu vermektedir. Bu veri seti için bu değerler her görselde aynıdır fakat veri setinde hem sınıflandırma hem de nesne tespiti amaçlandığı için xmin (nesnenin en soldaki koordinatı), ymin (nesnenin en üst noktasının koordinatı), xmax (nesnenin en sağının koordinatı), ymax (nesnenin en alt noktasının koordinatı) değişkenleriyle ifade edilen nesneye ait koordinatların normalize edilmesi için bu asıl boyut gereklidir. Class kolonunda ise görsel verinin ait olduğu sınıf, metin türünde belirtilmektedir.

Eğitimde kullanılmadan önce bu klasörler kod yardımıyla düzenlenmiş, her bir görsel ait olduğu sınıfın klasöründe olacak şekilde veri seti yapısı güncellenmiştir. Son durumda klasör yapısı aşağıdaki şekilde olmuştur:

dataset





3.2. Dental X-Ray Panoramic Dataset Veri Seti

Toplamda 2871 görüntüden oluşan veri seti YOLO için test, train ve valid olmak üzere üç klasöre ayrılmıştır. Bu veri setinde 31 farklı sınıf vardır.

- 0: Caries (Çürük)
- 1: Crown (Kron)
- 2: Filling (Dolgu)
- 3: Implant (İmplant)
- 4: Malaligned (Düzensiz Hizalanma)
- 5: Mandibular Canal (Alt Çene Kanalı)
- 6: Missing teeth (Eksik Dişler)
- 7: Periapical lesion (Periapikal Lezyon)
- 8: Retained root (Kalan Kök)
- 9: Root Canal Treatment (Kanal Tedavisi)
- 10: Root Piece (Kök Parçası)
- 11: Impacted tooth (Gömülü Diş)
- 12: Maxillary sinus (Maksiller Sinüs)

- 13: Bone Loss (Kemik Kaybı)
- 14: Fracture teeth (Kırık Dişler)
- 15: Permanent Teeth (Kalıcı Dişler)
- 16: Supra Eruption (Aşırı Sürme)
- 17: TAD (Geçici Ankraj Cihazı)
- 18: Abutment (Dayanak)
- 19: Attrition (Aşınma)
- 20: Bone defect (Kemik Defekti)
- 21: Gingival former (Diş Eti Şekillendiricisi)
- 22: Metal band (Metal Bant)
- 23: Orthodontic brackets (Ortodontik Braketler)
- 24: Permanent retainer (Kalıcı Sabitleyici)
- 25: Post-core (Post-Kor)
- 26: Plating (Plak)
- 27: Wire (Tel)
- 28: Cyst (Kist)
- 29: Root resorption (Kök Rezorpsiyonu)
- 30: Primary teeth (Süt Dişleri)

2871 görüntünün içinde bu sınıflara ait toplam 27141 örnek vardır. Bu örneklerin büyük bir bölümü (10058) dolgu örneklerinden oluşmaktadır. Onu 5859 örnek ile gömülü diş ve 3777 örnekle kanal tedavisi izlemektedir. Günlük hayatta en sık karşılaşılan durumlar olduğu için bu örneklere görüntülerde daha fazla rastlanmıştır.

Veri seti klasörlerinin içinde images klasörünün yanında labels klasörü de yer almaktadır. Labels klasörü, her bir görüntü için sınıf bilgilerini içeren etiket dosyalarını barındırmaktadır. Bu dosyalarda, sınıf numaraları ve bounding box (sınırlayıcı kutu) koordinatları bulunur. Her bir etiket dosyası, ilgili görüntüyle aynı ada sahiptir ve .txt formatındadır. Bu etiketler, YOLO modeli tarafından eğitim sırasında kullanılacaktır.

4. BULGULAR VE TARTIŞMA

Bu çalışmada 2 adet hazır veri kümesiyle CNN ve YOLO algoritmaları kullanılarak modeller eğitilmiş, performansları test edilmiştir. Hugging Face platformu üzerinden “AI-RESEARCHER-2024/AI-in-Dentistry” isimli bir çalışma bulunmuştur. 3 adet hazır modeli kullanarak analiz yapan bu uygulamanın Dental Görüntü Segmentasyonu yapan hazır modeli, kendi eğittiğimiz modellere bir örnek ve karşılaştırma teşkil etmesi amacıyla test edilmeye çalışılmıştır. Hastalık tespiti yapmasa da semantik segmentasyon gerçekleştiren bu modelin nesne tespiti aşamasında yararlı olabilecek potansiyele sahip olduğu düşünülmüştür [9].

4.1. Dental Radiography Veri Seti Deney ve Sonuçları

Kaggle platformundan elde edilen Dental Radiography veri setiyle eğitimler ve testler yapılmıştır [10]. Yapılan ilk eğitimde nesne tespiti eğitime dahil edilmemiş deneme amaçlı basit bir CNN modeli oluşturulmuştur. Model %46 accuracy değeri ile oldukça zayıf performans göstermiştir.

Layer (type)	Output Shape	Param #
conv2d_2 (Conv2D)	(None, 254, 254, 32)	896
max_pooling2d_2 (MaxPooling2D)	(None, 127, 127, 32)	0
conv2d_3 (Conv2D)	(None, 125, 125, 64)	18,496
max_pooling2d_3 (MaxPooling2D)	(None, 62, 62, 64)	0
flatten_1 (Flatten)	(None, 246016)	0
dense_1 (Dense)	(None, 128)	31,490,176
dense_2 (Dense)	(None, 4)	516

Şekil 4.1 İlk denenen basit CNN modelinin mimarisi

Tablo 4.1 İlk modelin performans metrikleri

Class	precision	recall	f1-score	support
Cavity	0.22	0.17	0.19	12
Fillings	0.49	0.65	0.56	57
Impacted Tooth	0.62	0.29	0.40	17
Implant	0.40	0.32	0.36	31

Model kaydedildikten sonra nesne tespiti için de eğitime dahil edilmesi için model_v2_bbox_added isimli başka bir model oluşturulmuştur. İlk denemede 10 epoch eğitim yapılmıştır. Ortalama mutlak hatayı hesaplayarak modelin tahminlerinin gerçek değerlerden ne kadar saptığını ölçen bbox_mae (Bounding Box Mean Absolute Error) metriğinin azalırken classification_accuracy metriğinin arttığı gözlemlenmiştir. Bu artışlar oldukça yetersiz ve loss değeri ciddi bir boyutta olduğundan aynı model mimarisi kullanılarak 30 epochla tekrar eğitim yapılmıştır.


Bu ikinci eğitimde classification_accuracy metriği en yüksek 0.8202'yi görmesine rağmen son epoch da düşüşe geçmiştir ve 0.7788 değeri ile sonlanmıştır. 0.4751 ile başlayan bbox_mae değeri ise 0.4780 ile biterek classification_accuracy aksine daha zayıf bir sonuç vermiştir.

Layer (type)	Output Shape	Param #	Connected to
input_layer_21 (InputLayer)	(None, 224, 224, 3)	0	-
flatten_21 (Flatten)	(None, 150528)	0	input_layer_21[0]...
dense_23 (Dense)	(None, 512)	77,070,848	flatten_21[0][0]
classification (Dense)	(None, 4)	2,052	dense_23[0][0]
bbox (Dense)	(None, 4)	2,052	dense_23[0][0]

Şekil 4.2 Bounding box kullanılarak eğitilen nesne tespiti model mimarisi

Model eğitiminde kullanılmayan test klasörüne ait görsel veriler seçilerek Bbox'lar ile birlikte modelin tahmin sonucu çıktı olarak bastırılmıştır. Hem veri setinin test klasöründen hem de bu veri seti dışından görsellerle tahmin yapılmıştır. Model bu aşamada yalnız 1 adet bbox ile tahmin yapabilmektedir dolayısıyla bir röntgene ait birden fazla nesneye ait sınıf tahmini yapılamamaktadır. Bundan sonrası için modelin birden fazla bbox ile birden fazla sınıfa ait çıktılar vermesi ve daha sonra da bu çıktıların hastalık kategorilerinde özelleştirilerek sonuçların analiz edilmesi planlanmaktadır.

Tahmin Edilen Sınıf: Implant
Olasılık: 1.0000



Şekil 4.3 Model v.2'nin dışarıdan bir veriyle yapılmış test sonuçları

4.2. Dental X-Ray Panoramic Dataset Veri Seti Deney ve Sonuçları

Deney Kaggle platformundan ulaşılan Dental X-Ray Panoramic Dataset [11] veri seti ile YOLO kullanılarak gerçekleştirilmiştir. YOLO, gerçek zamanlı nesne tespiti için kullanılan bir derin öğrenme modelidir. Model eğitimi için kullanılan YOLOv8 algoritması, derin öğrenme için özel olarak tasarlanmış Evrişimsel Sinir Ağlarına (CNN'ler) dayanan açık kaynaklı bir nesne algılama algoritmasıdır. You Only Look Once (YOLO) nesne algılama algoritmaları ailesinin bir parçası olarak, hız ve doğruluğu dengeleyen gerçek zamanlı nesne algılama yetenekleriyle bilinmektedir.


YOLOv8, görüntüyü bir grid yani ızgara yapısına bölerek ve her hücreinde belli işlemler

yaparak çalışmaktadır. Öncelikle tespit edilen nesne için sınır kutusu (bounding box) belirlenmekte daha sonra her sınırlanmış kutu için sınıf tahmini yapılmakta ve son olarak bir olasılık değeriyle sınıf tahmin değeri verilmektedir.

Kullanılan veri seti 31 farklı sınıfla etiketlenmiştir ve her bir görüntü nesnelerin sınıfı ve konumlarının bilgilerini içeren .txt dosyalarına sahiptir. Modeli eğitirken bu labels klasöründen faydalanılmıştır. Çalışma ortamı olarak Colab tercih edilmiştir ve çalışma zamanı olarak daha hızlı sonuç alabilmek için T4-GPU kullanılmıştır.

Model eğitilirken YOLOv8 modeli kullanılmıştır. Görüntü boyutu 640x640, batch size ise 16 olarak belirlenmiştir. Yani her iterasyonda 16 görüntü işlenmiştir. Model ilk önce 10 epoch ile eğitilmiştir, ama yeterli sonuç alınamadığı görüldüğünde 30 epoch ile eğitime karar verilmiştir.

Deney sonucunda modelin görüntüler üzerindeki çıktılarına ait bazı örnekler aşağıda yer almaktadır:



Şekil 4.4 Modelin rastgele iki test verisi üzerindeki çıktıları

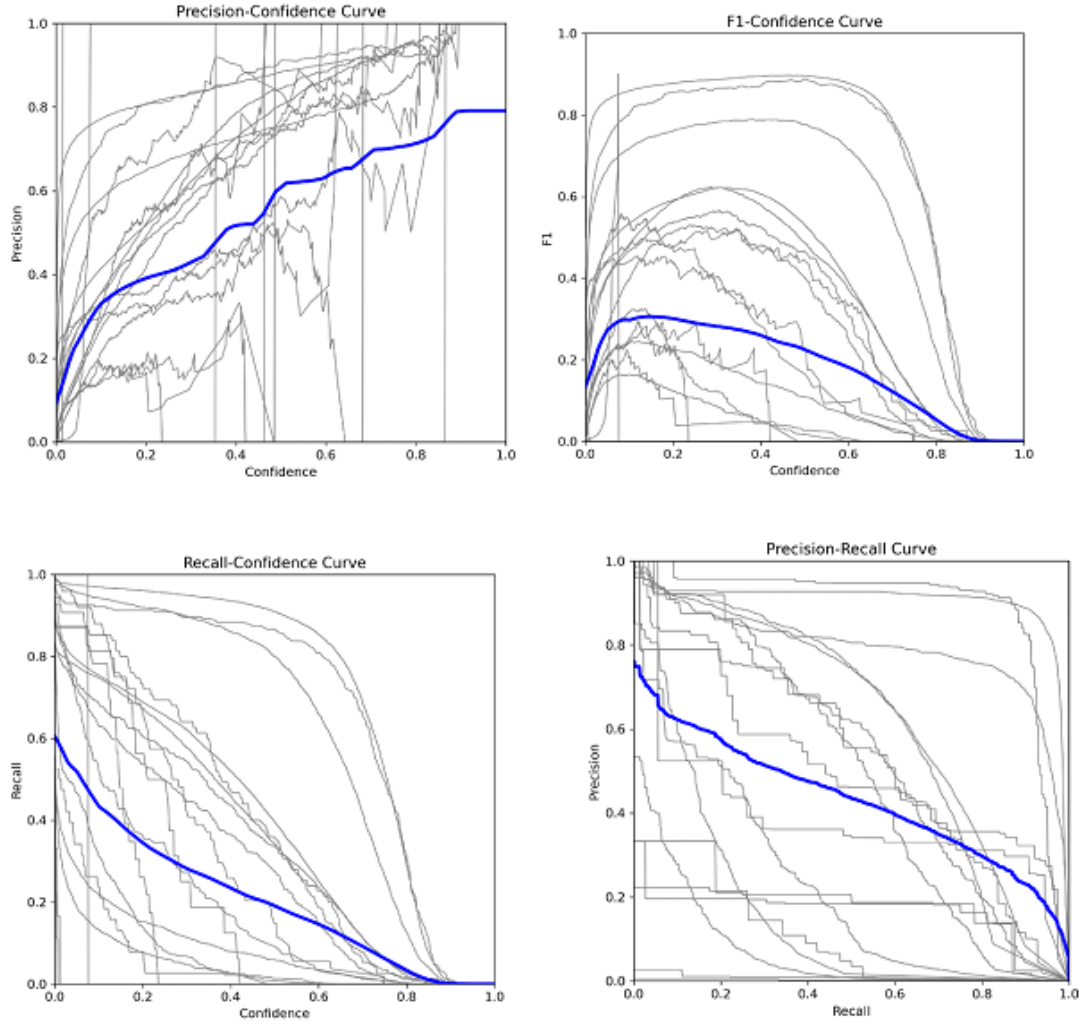
Modelin performans değerlendirmesinde precision, recal, mAP@0.5 ve mAP@0.5-0.95 metriklerine bakılmıştır. Modelin genel performansı toplam 2871 görüntü ve toplam 27141 örnek üzerinden değerlendirilmiştir. Precision ve Recall değerleri sırasıyla %37.2 ve %38.3 olup, modelin doğru pozitif tahminlerde sınırlı bir başarıya sahip olduğunu göstermektedir. Özellikle daha zorlu değerlendirme aralığı olan mAP@0.5-0.95 değerinin %17.5 olması modelin kompleks durumlarda düşük performans gösterdiğini ifade etmektedir.

Class	Images	Instances	Box(P	R	mAP50	mAP50-95):
all	2871	27141	0.372	0.383	0.343	0.175
Caries	614	2180	0.359	0.18	0.162	0.0571
Crown	797	2087	0.625	0.93	0.79	0.506
Filling	2046	10058	0.477	0.719	0.626	0.296
Implant	109	240	0.769	0.912	0.891	0.533
Malaligned	4	5	0	0	0	0
Mandibular Canal	38	75	0.354	0.8	0.509	0.295
Missing teeth	257	541	0.409	0.573	0.471	0.192
Periapical lesion	471	1132	0.279	0.0981	0.0721	0.0191
Retained root	2	6	0	0	0.00175	0.00114
Root Canal Treatment	1061	3777	0.448	0.703	0.611	0.266
Root Piece	181	426	0.43	0.646	0.543	0.229
impacted tooth	2416	5859	0.796	0.965	0.906	0.558
maxillary sinus	27	54	0.309	0.741	0.39	0.262
Bone Loss	212	484	0.5	0.211	0.231	0.105
Fracture teeth	2	2	0	0	0	0
Supra Eruption	8	9	1	0	0.00928	0.00509
abutment	8	15	0	0	0	0
gingival former	2	2	0	0	0	0
metal band	1	1	1	0	0.995	0.399
orthodontic brackets	9	16	0.177	0.75	0.203	0.0914
post - core	25	38	0.165	0.12	0.0805	0.0252
wire	14	23	0.153	0.424	0.167	0.0661
Cyst	1	1	0	0	0	0
Primary teeth	9	110	0.686	0.427	0.561	0.287

Şekil 4.5 Modelin sınıf bazlı performans metrikleri

Sınıf bazında değerlendirildiğinde, dolgu %62.6, gömülü diş %90.6 ve kanal tedavisi %61.1 sınıflarında başarılı sonuçlar elde edilmiştir. Özellikle, örnek sayısı az olan "Malaligned", "Retained root" ve "Fracture teeth" sınıflarında modelin başarısız olduğu görülmektedir. Veri setinin dengesiz yapısı ve bazı sınıflarda düşük örnek sayılarının olması modelin performansını olumsuz etkilemiştir. İlerleyen aşamalarda veri artırımı, epoch sayısının artırılması ve model optimizasyonları ile daha başarılı sonuçlar elde edilmesi hedeflenmektedir.

Model performansı ile ilgili grafiklere aşağıda yer verilmiştir:



Şekil 4.7 Precision, Recall, Confidence, F1 Grafikleri

4.3. Hazır Model Kullanımı

Konuyla ilgili Hugging Face platformu üzerinden “AI-RESEARCHER-2024/AI-in-Dentistry” isimli bir çalışma bulunmuştur. Bu repository 3 adet modeli temel almaktadır:

Calculus and Caries Detection (Calculus ve Çürük Tespiti): Bu model VGG mimarisine dayanmaktadır ve Dental Durum Veri Kümesi üzerinde eğitilmiştir.

Caries Detection (Çürük Tespiti): Bu model Yolov8 modelini kullanarak çürük tespiti yapar, Yolov8 Çürük Dedektöründen alınmıştır.

Dental Image Segmentation (Dental Görüntü Segmentasyonu): Bu model, U-Net Modeli ile derin öğrenme yöntemini kullanarak tek çekim panoramik röntgen görüntüsünde semantik segmentasyon gerçekleştirir. Modelin kaynağı Segmentation-of-

Teeth-in-Panoramic-X-ray-Image-Using-U-Net'tir.

Çalışmamızda panoramik röntgen görüntüleri kullanıldığı fakat buradaki ilk iki modelde gerçek ağız fotoğrafları temel alındığı için bu iki model bu çalışma için faydalı bulunmamaktadır. 3.model ise nesne tespiti aşamasında yararlı olabilecek potansiyele sahiptir. Uygulama lokal olarak bilgisayarımızda çalıştırılmış fakat model tahmini kısmında kütüphanelerin versiyon uyumsuzlukları nedeniyle hata alınmıştır. İlerde bu uyumsuzluklar giderilerek hazır model sonuçlarının eğitilmiş model sonuçlarıyla karşılaştırılması hedeflenmektedir.

5. SONUÇLAR

Bu proje çalışmasında 2 farklı veri kümesi ile 2 farklı derin öğrenme algoritması (CNN ve YOLO) kullanılarak modeller geliştirilmiş, sonuçları test edilmiştir. CNN ve Dental Radiography veri seti kullanılarak eğitilen modelinin pratikte test görselleri üzerinde güzel sonuçlar verdiği fakat birden fazla nesne tespit edemeyip tek bbox'a ait tek bir sınıflandırma yapabildiği tespit edilmiştir. Bu durum ağız içerisindeki birden fazla hastalık veya sınıflandırma bulunması durumunda modelin yalnızca en çok emin olduğu bir sınıfı bulacağı anlamına gelmektedir. Dolayısıyla ileride istenilen performansı sağlamak adına daha detaylı nesne tespiti ve birden fazla nesneye ait sınıflandırma yapılması üzerine yoğunlaşılması hedeflenmektedir.

YOLO algoritması ve Dental X-Ray Panoramic Dataset kullanılarak eğitilen modelin tahminlerinde nesne tespiti sonuçları tatmin edicidir. Model ağız röntgeni üzerinde birden fazla bbox'u ayrı ayrı sınıflandırabilmektedir. İleri aşamalarda 30 adet sınıfı bulunan bu modelin eğitim performansını arttırmak amacıyla daha gelişmiş YOLO teknikleri kullanmak hedeflenmektedir.

Çalışmaya katkı sunması için hazır bir model test edilerek kendi modellerimizle karşılaştırılmak istenmiştir. Tam olarak istenilen şekilde sınıflandırma yapan bir model bulunamasa da nesne tespiti yapan bir model bulunmuştur. Model denenmiş fakat versiyon uyumsuzlukları nedeniyle hata alınmış ve modele tahmin yaptırılmamıştır. İlerisi için bu hataların giderilerek modelin çalıştırılıp gözlemlenmesi amaçlanmaktadır.

Çalışma süresince kendi veri setimizi oluşturmak için panoramik diş görüntüleri toplanmıştır. 100'den fazla görüntü toplandıktan sonra bunların etiketlenmesi için

alıřmalar yapılmaya başlanmıřtır.

KAYNAKLAR

- [1] M. K. Dhar and M. Deb, “S-R2F2U-Net: A single-stage model for teeth segmentation,” *arXiv*, 2023. [Online]. Available: <https://arxiv.org/abs/2204.02939>.
- [2] Zeng, X., Wen, L., Xu, Y., & Ji, C. (2020). Generating Diagnostic Report for Medical Image by High-middle-level Visual Information Incorporation on Double Deep Learning Models. *Computer Methods and Programs in Biomedicine*, 197, 105700.
- [3] Ünsal, Ü., & Adem, K. (2023). Diş Görüntüleri Üzerinde Görüntü İşleme ve Derin Öğrenme Yöntemleri Kullanılarak Çürük Seviyesinin Sınıflandırılması. *Uluslararası Sivas Bilim Ve Teknoloji Üniversitesi Dergisi*, 2(2), 30-53.
- [4] Suryani, D., Shoumi, M., & Wakhidah, R. (2021). Object detection on dental x-ray images using deep learning method. *IOP Conference Series: Materials Science and Engineering*, 1073, 012058.
- [5] Hasnain, M. A., Ali, S., Malik, H., Irfan, M., & Maqbool, M. S. (2023). Deep Learning-Based Classification of Dental Disease Using X-Rays. *Journal of Computational and Biophysical Insights*, 5(01), 82-95.
- [6] Schwendicke, F., Golla, T., Dreher, M., & Krois, J. (2019). Convolutional neural networks for dental image diagnostics: A scoping review. *Journal of Dentistry*, 91, 103226.
- [7] <https://time.com/7094716/overjet/>
- [8] <https://www.hellopearl.com/>
- [9] <https://huggingface.co/AI-RESEARCHER-2024/AI-in-Dentistry>
- [10] <https://www.kaggle.com/datasets/imtkaggleteam/dental-radiography/data>
- [11] <https://www.kaggle.com/datasets/lokisilvres/dental-disease-panoramic-detection-dataset/data>